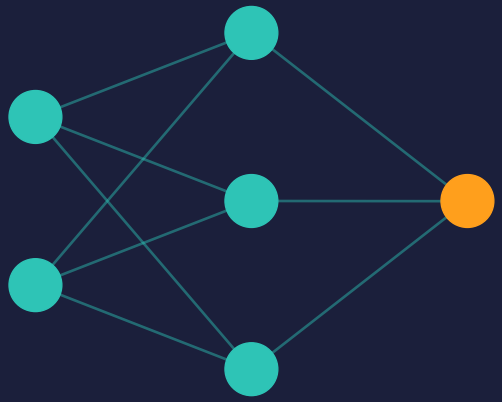
دوره یادگیری عمیق و شبکه‌های عصبی



جلسه ۱۱

LSTM، GRU و Word Embedding برای دسته‌بندی متن

دروازه‌ها، حافظه بلندمدت و تحلیل احساس نقدهای فیلم IMDB

کیوان محمودی

در این جلسه

۱ از RNN به LSTM

۲ حالت سلول و سه دروازه

۳ GRU: نسخه ساده‌تر

۴ دیتاست IMDB

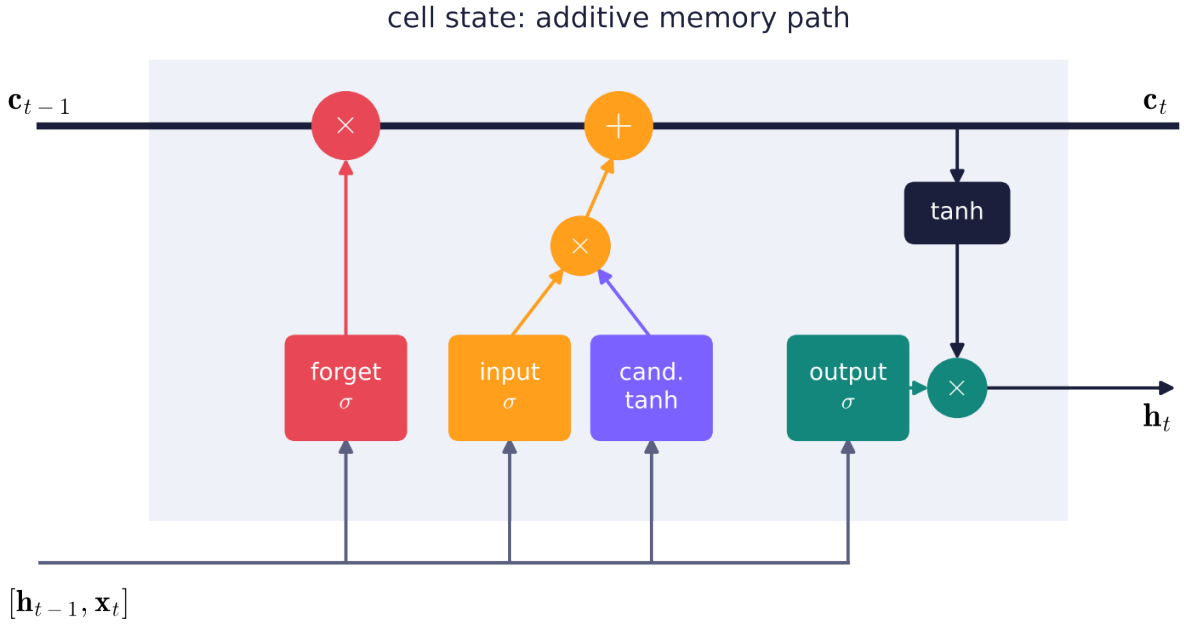
۵ Tokenization و واژگان

۶ Padding و Packing

۷ Word Embedding

۸ LSTM دوطرفه و خط مبنا

سلول LSTM



حالت سلول با به‌روزرسانی جمعی اطلاعات را در زمان منتقل می‌کند؛ سه دروازه Sigmoid جریان اطلاعات را کنترل می‌کنند

معادلات LSTM

$$\mathbf{f}_t = \sigma(W_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad \mathbf{i}_t = \sigma(W_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad \mathbf{o}_t = \sigma(W_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o)$$

$$\tilde{\mathbf{c}}_t = \tanh(W_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) \qquad \mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \qquad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)$$

- Forget: چه چیزی از حافظه پاک شود؛ Input: چه مقدار اطلاعات جدید نوشته شود
- Output: چه بخشی از حافظه به حالت پنهان برود
- مشتق حالت سلول نسبت به حالت قبلی برابر f است؛ با f نزدیک ۱، گرادیان محو نمی‌شود.

LSTM یا GRU؟

LSTM (1997)

- حالت سلول و حالت پنهان جدا
- سه دروازه: Forget، Input و Output
- با ورودی ۱۰۰ و حالت ۱۲۸: ۱۱۷,۷۶۰ پارامتر

GRU (2014)

- یک حالت واحد
- دو دروازه: Update و Reset
- با همان ابعاد: ۸۸,۳۲۰ پارامتر (۲۵٪ کمتر)
- معمولاً عملکرد مشابه LSTM

سلول LSTM از صفر

```
class MyLSTMCell(nn.Module):
    def __init__(self, input_size, hidden_size):
        super().__init__()
        self.x2g = nn.Linear(input_size, 4 * hidden_size)
        self.h2g = nn.Linear(hidden_size, 4 * hidden_size)

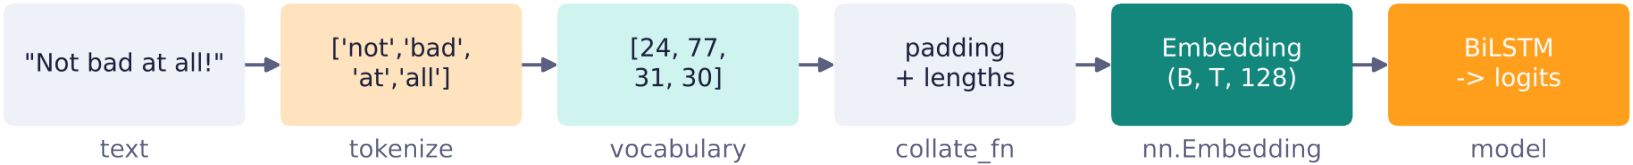
    def forward(self, x, state):
        h, c = state
        i, f, g, o = (self.x2g(x) + self.h2g(h)).chunk(4, dim=1)
        i, f, o = torch.sigmoid(i), torch.sigmoid(f), torch.sigmoid(o)
        c = f * c + i * torch.tanh(g)      # additive update
        h = o * torch.tanh(c)
        return h, c
```

- چهار تبدیل خطی در یک ماتریس بزرگ
- ترتیب PyTorch: input، forget، cell، output
- خروجی دقیقاً برابر nn.LSTMCell شد.

دیتاست IMDB

- ۵۰,۰۰۰ نقد فیلم انگلیسی با برچسب مثبت یا منفی (Maas et al., 2011)
- ۲۵,۰۰۰ برای آموزش و ۲۵,۰۰۰ برای آزمون؛ کاملاً متوازن
- بارگذاری از Hugging Face Hub با کتابخانه datasets
- طول نقدها بسیار متغیر است؛ آن‌ها را به ۲۵۶ Token کوتاه می‌کنیم.

از متن به تنسور



واژگان فقط از داده آموزشی و با پرتکرارترین ۲۰,۰۰۰ کلمه؛ دو Token ویژه: <pad> و <unk>

Padding در collate_fn و Packing در مدل

```
def collate(batch):
    seqs, labels = zip(*batch)
    lengths = torch.tensor([len(s) for s in seqs])
    padded = pad_sequence(seqs, batch_first=True, padding_value=PAD)
    return padded, lengths, torch.stack(labels)

# inside the model
packed = pack_padded_sequence(emb, lengths.cpu(), batch_first=True,
                              enforce_sorted=False)
_, (h_n, c_n) = self.lstm(packed)
last = torch.cat([h_n[-2], h_n[-1]], dim=1)   # both directions
```

- Padding: هم‌طول کردن دنباله‌های یک Batch
- Packing: LSTM روی Tokenهای <pad> محاسبه نمی‌کند.
- h_n حالت آخرین Token واقعی هر دنباله است.

Word Embedding

One-hot

- بردار به طول واژگان (۲۰,۰۰۰)
- بسیار بزرگ و تُنُک
- هیچ مفهوم شباهتی ندارد.

Embedding چگال

- بردار کوچک (مثلاً ۱۲۸ بعدی) و یادگرفتنی
- کلمات مشابه بردارهای نزدیک دارند.
- nn.Embedding: یک جدول جست‌وجوی قابل آموزش
- ازپیش‌آموزش‌دیده: Word2Vec، GloVe و fastText

سه مدل برای مقایسه

۱ میانگین Embedding

ترتیب کلمات را نادیده می‌گیرد؛ خط مبنای ساده اما بسیار قوی برای تحلیل احساس

۲ GRU دوطرفه

ترتیب را مدل می‌کند؛ پارامتر کمتر از LSTM

۳ LSTM دوطرفه

الگوهایی مثل نفی را بهتر مدل می‌کند: not good در برابر good

جمع‌بندی

- LSTM با حالت سلول و سه دروازه، حافظه بلندمدت را با به‌روزرسانی جمعی حفظ می‌کند.
- GRU نسخه ساده‌تر با دو دروازه و عملکرد مشابه است.
- خط لوله متن: توکن‌سازی، ساخت واژگان، تبدیل به عدد و Padding
- nn.Embedding کلمات را به بردارهای چگال قابل آموزش تبدیل می‌کند.
- pack_padded_sequence محاسبه روی Padding را حذف می‌کند.
- همیشه با یک خط مبنای ساده مقایسه کنید.

تمرین

۱ سلول GRU را از صفر پیاده‌سازی و با nn.GRUCell تطبیق دهید.

۲ طول بیشینه را ۶۴ و ۵۱۲ بگیرید؛ دقت و زمان چه تغییری می‌کند؟

۳ به‌جای حالت نهایی، Max Pooling روی زمان را به طبقه‌بند بدهید.

۴ Embeddingهای GloVe را بارگذاری کنید؛ یک بار منجمد و یک بار قابل آموزش

۵ همین خط لوله را روی یک دیتاست احساس فارسی اجرا کنید.