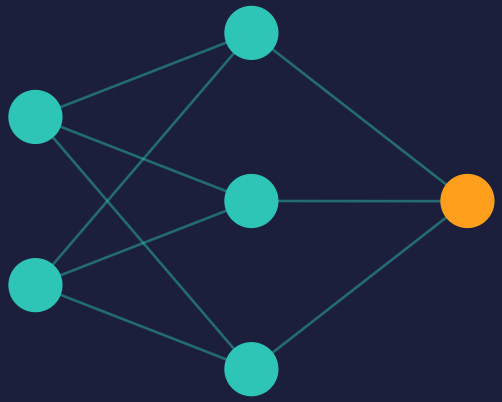
دوره یادگیری عمیق و شبکه‌های عصبی



جلسه ۱۲

مدل‌های Sequence-to-Sequence و سازوکار Attention

Encoder–Decoder، Teacher Forcing و Attention افزایشی با مثال تبدیل تاریخ

کیوان محمودی

در این جلسه

۱ مسئله Sequence-to-Sequence

۲ مثال: تبدیل تاریخ

۳ معماری Encoder–Decoder

۴ Teacher Forcing

۵ گلوگاه بردار زمینه

۶ Attention افزایشی (Bahdanau)

۷ نقشه Attention

۸ از Attention به Transformer

مسئله: دنباله به دنباله با طول متفاوت

- ترجمه ماشینی، خلاصه‌سازی، پاسخ به پرسش و سیستم‌های گفت‌وگو
- مثال کلاس: تبدیل تاریخ‌های نوشته‌شده به شکل‌های مختلف به قالب ISO
  - saturday, march 3, 2021 → 2021-03-03
  - 1998-11-17 → 17.11.1998
- مدل باید روز، ماه و سال را تشخیص دهد، نام ماه را به عدد تبدیل کند و ترتیب را عوض کند.
- مدل در سطح کاراکتر؛ آموزش روی CPU در چند دقیقه

معماری Encoder–Decoder

Encoder

- کل دنباله ورودی را می‌خواند (GRU دوطرفه).
- آن را در یک بردار خلاصه می‌کند: بردار زمینه

Decoder

- با شروع از بردار زمینه، خروجی را Token به Token تولید می‌کند.
- هر Token تولیدشده ورودی گام بعد است.
- تا تولید Token ویژه <eos> ادامه می‌دهد.

Teacher Forcing

```
tgt_in, tgt_out = tgt[:, :-1], tgt[:, 1:]   # shift by one step
# tgt_in : <sos> 2 0 2 1 - 0 3 - 0
# tgt_out:  2 0 2 1 - 0 3 - 0 3 <eos>

logits = model(src, tgt_in)
loss = F.cross_entropy(logits.reshape(-1, V), tgt_out.reshape(-1),
                       ignore_index=PAD)
```

- در آموزش، Token درست (نه پیش‌بینی مدل) ورودی گام بعد است.
- آموزش سریع‌تر و پایدارتر
- عیب: Exposure Bias؛ در استفاده، مدل روی پیش‌بینی‌های خودش کار می‌کند.
- ignore_index مکان‌های Padding را از Loss حذف می‌کند.

گلوگاه بردار زمینه

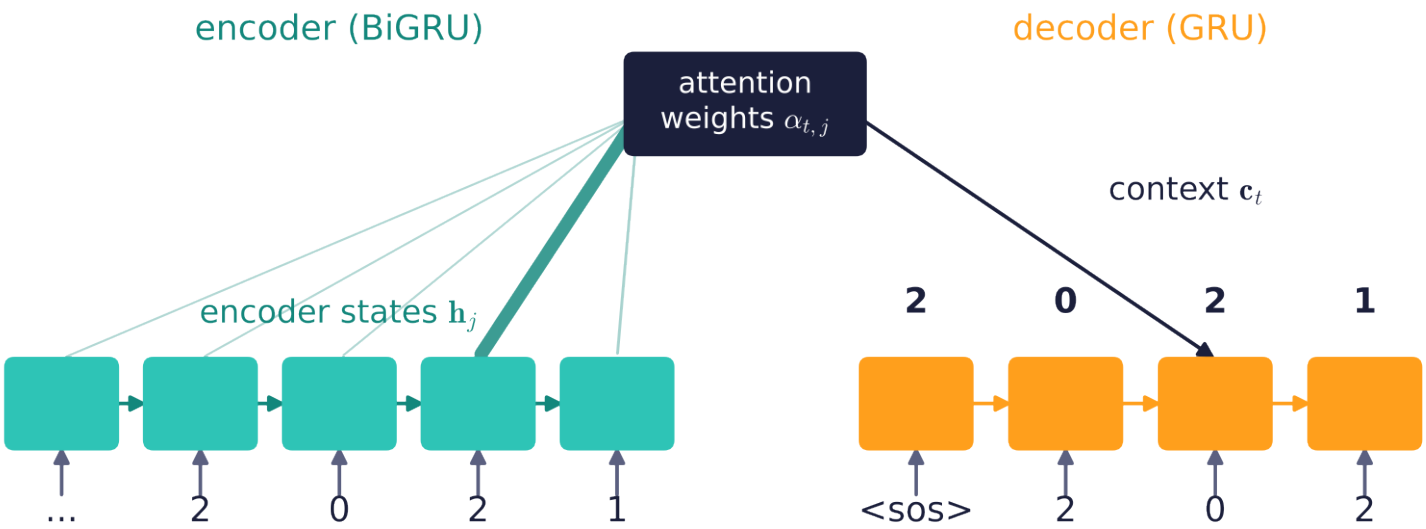
مشکل

- کل اطلاعات ورودی باید در یک بردار ثابت فشرده شود.
- با جمله‌های طولانی کیفیت ترجمه به‌شدت افت می‌کند.

ایده Attention

- Decoder در هر گام به همه حالت‌های Encoder نگاه می‌کند.
- خودش تصمیم می‌گیرد روی کدام بخش ورودی تمرکز کند.
- Bahdanau, Cho & Bengio (2015)

Attention با Seq2Seq



در هر گام، میانگین وزن‌دار حالت‌های Encoder یک بردار زمینه مخصوص همان گام می‌سازد

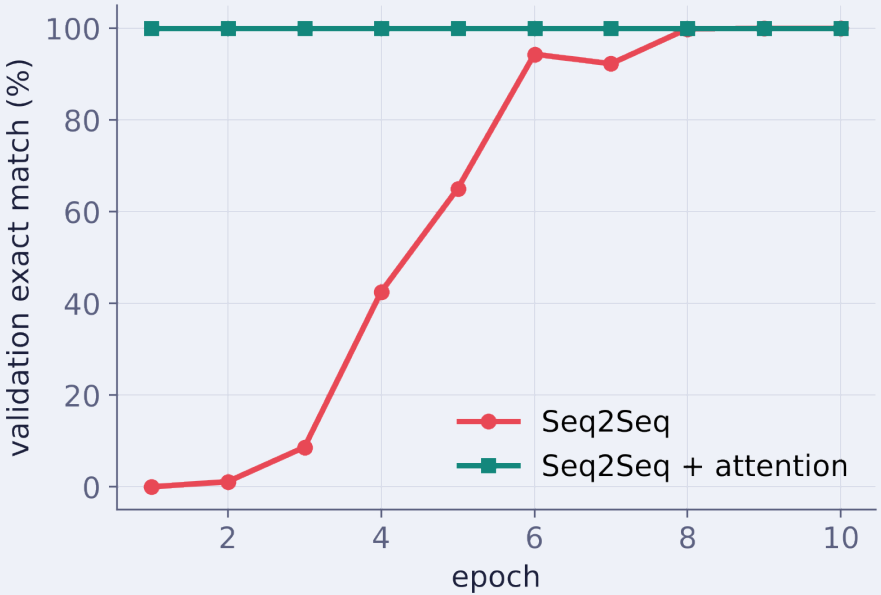
Attention افزایشی (Bahdanau)

$$e_{t,j} = \mathbf{v}^\top \tanh\left(W_s\,\mathbf{s}_{t-1} + W_h\,\mathbf{h}_j\right)$$

$$\alpha_{t,j} = \frac{\exp(e_{t,j})}{\sum_k \exp(e_{t,k})} \qquad \mathbf{c}_t = \sum_j \alpha_{t,j}\,\mathbf{h}_j$$

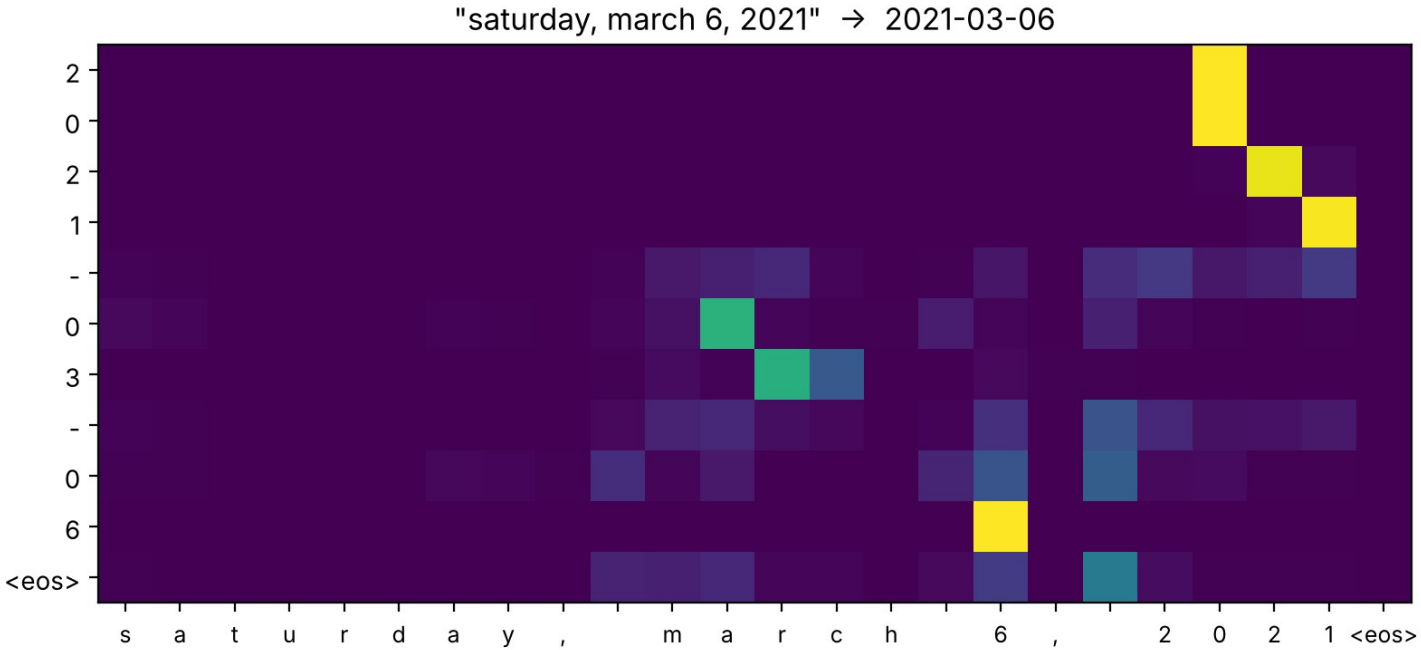
- امتیاز هر مکان ورودی با حالت فعلی Decoder
- Softmax روی امتیازها؛ مکان‌های Padding با منفی بی‌نهایت حذف می‌شوند.
- بردار زمینه به همراه Embedding Token قبلی ورودی GRU می‌شود.

نتیجه: Attention بسیار سریع‌تر یاد می‌گیرد



- با Attention: دقت کامل از همان Epoch اول
- بدون Attention: چندین Epoch لازم است.
- دقت نهایی آزمون: ۹۹/۹۳٪ بدون Attention و ۱۰۰/۰۰٪ با آن
- مهم‌تر از دقت: Attention مدل را قابل تفسیر می‌کند.

نقشه Attention: هم‌ترازی یادگرفته‌شده



هنگام تولید سال به ارقام سال، هنگام تولید ماه به نام ماه و هنگام تولید روز به عدد روز نگاه می‌کند؛ هیچ‌کس این را به مدل نگفته است

فراتر از این جلسه

۱ Beam Search

به‌جای انتخاب حریصانه، k دنباله جزئی محتمل‌تر را در هر گام نگه می‌دارد.

۲ Sampling

در مدل‌های زبانی بزرگ: Temperature و Top-p (جلسه ۱۳)

۳ Transformer

حذف کامل RNN و استفاده فقط از Attention؛ پردازش موازی کل دنباله

جمع‌بندی

- Encoder–Decoder دنباله را به دنباله‌ای با طول متفاوت تبدیل می‌کند.
- Teacher Forcing: ورودی و خروجی Decoder یک گام جابه‌جا هستند.
- Masking و Padding، ignore_index را از محاسبات حذف می‌کنند.
- بردار زمینه ثابت یک گلوگاه است.
- Attention در هر گام میانگین وزن‌دار حالت‌های Encoder را می‌سازد.
- وزن‌های Attention هم‌ترازی ورودی و خروجی را نشان می‌دهند.

تمرین

۱ Attention ضرب نقطه‌ای (Luong) را پیاده کنید و با Bahdanau مقایسه کنید.

۲ قالب‌های تاریخ جدید اضافه کنید و رفتار مدل را روی قالب‌های ناآشنا ببینید.

۳ Scheduled Sampling را پیاده کنید.

۴ Beam Search با اندازه پرتو ۳ را پیاده کنید.

۵ مسئله تبدیل عدد نوشته‌شده با حروف به رقم را با همین کد حل کنید.