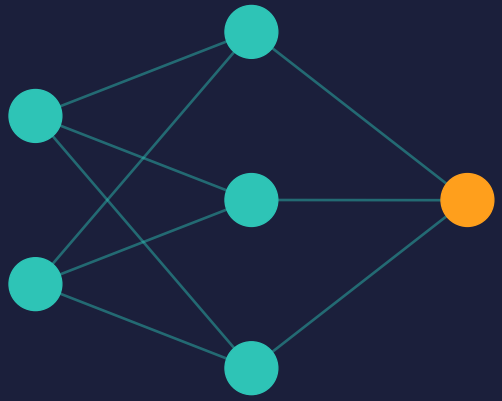
دوره یادگیری عمیق و شبکه‌های عصبی



جلسه ۱۴

مدل‌های ازپیش‌آموزش‌دیده با Hugging Face

تحلیل احساس نظرات فارسی با Fine-tuning مدل ParsBERT

کیوان محمودی

در این جلسه

۱ پیش‌آموزش و Fine-tuning

۲ اکوسیستم Hugging Face

۳ pipeline و Fill-Mask

۴ Tokenizerهای زیرکلمه‌ای

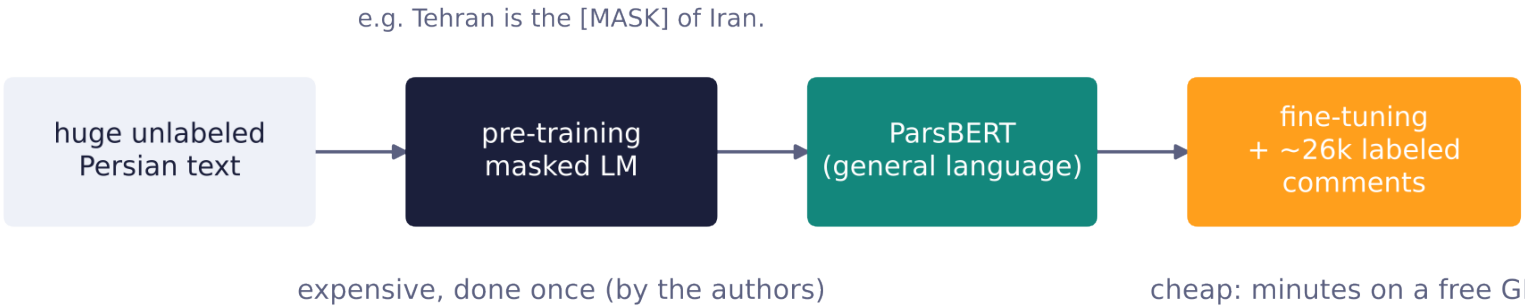
۵ دیتاست نظرات دیجی‌کالا و اسنپ‌فود

۶ datasets.map و Dynamic Padding

۷ Fine-tuning مدل ParsBERT

۸ ارزیابی، ذخیره و استفاده

الگوی غالب NLP امروز



BERT روی متن عظیم با Masked Language Modeling پیش‌آموزش می‌بیند و با داده برچسب‌دار کم برای هر مسئله Fine-tune می‌شود

اکوسیستم Hugging Face

۱ Hub

مخزن صدها هزار مدل و دیتاست؛
مثل گیت‌هاب برای مدل‌ها

۲ transformers

رابط یکسان برای همه مدل‌ها:
AutoTokenizer و AutoModel

۳ datasets

بارگذاری و پردازش کارای دیتاست‌ها
با map

شروع سریع: pipeline

```
from transformers import pipeline

fill_mask = pipeline('fill-mask',
                     model='HooshvareLab/bert-fa-base-uncased')
fill_mask('تهران [MASK] است ایران.', top_k=5)
```

- pipeline پیش‌پردازش، اجرای مدل و پس‌پردازش را یکجا انجام می‌دهد.
- ParsBERT بدون آموزش اضافه جای خالی را با کلمات مناسب پر می‌کند.
- این دانش زبانی پایه Fine-tuning است.

Tokenizerهای زیرکلمه‌ای

سطح کلمه (جلسه ۱۱)

- واژگان بزرگ
- کلمات ناشناخته به <unk> تبدیل می‌شوند.
- برای زبانی با تکواژهای فراوان مثل فارسی ضعیف است.

زیرکلمه (WordPiece و BPE)

- کلمات پرتکرار یک Token، کلمات کم‌تکرار چند قطعه
- تقریباً هیچ کلمه‌ای ناشناخته نمی‌ماند.
- BERT از WordPiece و GPT از BPE استفاده می‌کند.
- ParsBERT حدود ۱۰۰ هزار Token دارد.

خروجی Tokenizer

```
tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)
batch = tokenizer(['خیلی خوب بود',
                   'اصلا راضی نبودم و پولم هدر رفت'],
                  padding=True, truncation=True,
                  max_length=16, return_tensors='pt')

batch['input_ids']        # [CLS] ... [SEP] [PAD] ...
batch['attention_mask']   # 1 for real tokens, 0 for padding
```

- [CLS] در ابتدا: نماینده کل جمله برای طبقه‌بندی
- [SEP] در انتها و بین دو جمله
- attention_mask مکان‌های Padding را مشخص می‌کند.
- BERT حداکثر ۵۱۲ Token می‌پذیرد.

دیتاست: نظرات دیجی‌کالا و اسنپ‌فود

- hezarai/sentiment-dksf از پروژه متن‌باز هزار
- حدود ۳۱ هزار نظر کاربران فارسی‌زبان
- سه برچسب: منفی، مثبت و خنثی (نامتوازن)
- ابتدا چند نمونه از هر برچسب را بخوانید تا از نگاشت عدد به نام مطمئن شوید.
- ۱۰٪ داده آموزشی برای اعتبارسنجی جدا می‌شود.

Tokenize کردن دیتاست و Dynamic Padding

```
def tokenize_batch(batch):
    return tokenizer(batch['text'], truncation=True, max_length=128)

train = split['train'].map(tokenize_batch, batched=True,
                           remove_columns=['text'])
train.set_format('torch')

collator = DataCollatorWithPadding(tokenizer)
train_loader = DataLoader(train, batch_size=32, shuffle=True,
                          collate_fn=collator)
```

- map با batched=True بسیار سریع است.
- Padding در زمان ساخت هر Batch و فقط تا طول بلندترین نمونه همان Batch

مدل و حلقه Fine-tuning

```
model = AutoModelForSequenceClassification.from_pretrained(
    MODEL_NAME, num_labels=3, id2label=id2label, label2id=label2id)

optimizer = torch.optim.AdamW(param_groups, lr=3e-5)
scheduler = get_linear_schedule_with_warmup(
    optimizer, num_warmup_steps=int(0.06 * total_steps),
    num_training_steps=total_steps)

for batch in train_loader:
    loss = model(**batch).loss       # labels in the batch
    loss.backward(); optimizer.step(); scheduler.step()
    optimizer.zero_grad()
```

- یک سر طبقه‌بند جدید روی بردار [CLS]
- نرخ یادگیری کوچک: ۲ تا ۵ ضرب در ۱۰ به توان منفی ۵
- Warmup خطی و فقط ۲ تا ۴ Epoch
- بدون Weight Decay روی بایاس و LayerNorm

ارزیابی و استفاده

ارزیابی

- کلاس‌ها نامتوازن‌اند؛ Macro-F1 گزارش دهید.
- Classification Report و Confusion Matrix
- کلاس خنثی سخت‌ترین است؛ مرزش با بقیه مبهم است.

استفاده و انتشار

- pipeline با مدل Fine-tuneشده
- model.save_pretrained و tokenizer.save_pretrained
- انتشار با push_to_hub در حساب Hugging Face
- جایگزین حلقه دستی: کلاس Trainer

جمع‌بندی

- پیش‌آموزش روی متن عظیم بدون برچسب، سپس Fine-tuning با داده کم
- pipeline برای استفاده سریع؛ AutoTokenizer و AutoModel برای کنترل کامل
- Tokenizerهای زیرکلمه‌ای مشکل کلمات ناشناخته را حل می‌کنند.
- datasets.map برای Tokenize و DataCollatorWithPadding برای Padding پویا
- برای Fine-tuning از AdamW با نرخ کوچک، Warmup خطی و ۲ تا ۴ Epoch استفاده کنید.
- برای داده نامتوازن Macro-F1 گزارش دهید.

تمرین

۱ نرخ یادگیری را ده به توان منفی ۵ و ده به توان منفی ۴ بگیرید؛ با نرخ بزرگ چه می‌شود؟

۲ مدل چندزبانه xlm-roberta-base را Fine-tune و با ParsBERT مقایسه کنید.

۳ بدنه BERT را منجمد کنید و فقط سر طبقه‌بند را آموزش دهید.

۴ طول بیشینه را ۶۴ بگیرید و با هیستوگرام طول نظرات تصمیم بگیرید.

۵ مدل را با push_to_hub منتشر کنید و یک Model Card بنویسید.